

Laporan Teknis Proyek Guardian Alert: Sistem Deteksi Jatuh

Tanggal: 07 Mei 2026

1. Pendahuluan

Proyek Guardian Alert bertujuan untuk mengembangkan sistem deteksi jatuh bagi lansia menggunakan data sensor Inertial Measurement Unit (IMU). Jatuh merupakan penyebab utama cedera serius pada populasi lansia, dan deteksi dini serta respons cepat dapat secara signifikan mengurangi dampak negatifnya. Laporan teknis ini merinci seluruh proses pengembangan, mulai dari penemuan masalah hingga implementasi model akhir.

2. Penemuan Masalah dan Pertanyaan Bisnis

Pernyataan Masalah: Jatuh adalah penyebab utama cedera di kalangan lansia. Deteksi dan respons yang cepat dapat secara signifikan mengurangi tingkat keparahan cedera ini. Tujuan dari proyek ini adalah untuk mengembangkan model machine learning yang mampu membedakan secara akurat antara Aktivitas Kehidupan Sehari-hari (ADL) dan kejadian jatuh yang sebenarnya menggunakan data sensor IMU.

Pertanyaan Bisnis:

1. Pola sensor apa yang membedakan jatuh dari aktivitas normal (ADL)?
2. Sumbu/fitur sensor mana yang paling prediktif terhadap kejadian jatuh?
3. Apakah ada perbedaan pola jatuh antara subjek dewasa dan lansia?
4. Berapa set fitur minimum yang diperlukan untuk deteksi jatuh yang akurat?
5. Seberapa akurat kita dapat mendeteksi jatuh menggunakan data sensor IMU?

3. Data Wrangling (Pengumpulan, Penilaian, Pembersihan)

Dataset yang digunakan adalah SisFall, yang berisi data dari 38 subjek (23 dewasa, 15 lansia) yang melakukan 19 aktivitas ADL dan 15 aktivitas Jatuh. Data dikumpulkan menggunakan 3 sensor (2 akselerometer, 1 giroskop) pada frekuensi 200 Hz. Setiap file data adalah .txt dengan 9 kolom nilai ADC mentah, diakhiri dengan tanda titik koma.

Langkah-langkah Data Wrangling:

- **Pengumpulan Data:** Data mentah diperoleh dari dataset SisFall (`data/SisFall_dataset/`).
- **Penilaian Data:** Struktur file .txt dianalisis, termasuk keberadaan titik koma di akhir setiap baris dan format nilai ADC.
- **Pembersihan Data:**
 - Menghapus tanda titik koma di akhir setiap baris.
 - Mengonversi nilai ADC mentah ke satuan fisik menggunakan formula berikut:
 - ADXL345 (Akselerometer 1, kolom 0-2): `raw * (32 / 8192)` -> unit: g
 - ITG3200 (Girooskop, kolom 3-5): `raw * (1 / 14.375)` -> unit: deg/s
 - MMA8451Q (Akselerometer 2, kolom 6-8): `raw * (16 / 16384)` -> unit: g
 - Untuk model LSTM, hanya 6 kolom pertama (ADXL345 + ITG3200) yang digunakan.
 - Melakukan sampling 83 file representatif untuk menyeimbangkan dataset dan mengurangi waktu pemrosesan.

Data Dictionary (untuk Tim AI Engineering):

- **kelompok:** Kategori subjek (Dewasa atau Lansia).
- **adxl_x_max:** Nilai maksimum sumbu X dari akselerometer ADXL345 (contoh fitur statistik).
- **label:** Label aktivitas (ADL atau FALL).
- **X_dl.npy:** Data input untuk Deep Learning, berbentuk 3D array (`jumlah_sampel, 200, 6`). 200 adalah timestep dan 6 adalah jumlah fitur sensor (Accel X/Y/Z, Gyro X/Y/Z).

- **y_dl.npy**: Label untuk Deep Learning, berbentuk 1D array (`jumlah_sampel,`).

4. Analisis Data Eksploratif (EDA)

EDA dilakukan untuk memahami distribusi label dan aktivitas dalam dataset. Ini membantu mengidentifikasi potensi ketidakseimbangan kelas dan karakteristik data sensor untuk aktivitas ADL dan Jatuh. Visualisasi seperti distribusi frekuensi label dan pola sinyal sensor untuk kedua kelas aktivitas telah dibuat untuk mendapatkan insight awal.

5. Pengembangan Model Baseline: Random Forest

Sebagai model baseline, Random Forest diimplementasikan. Model ini menggunakan pendekatan berbasis fitur statistik. Sebanyak 75 fitur statistik diekstraksi dari data sensor, seperti nilai maksimum, minimum, rata-rata, standar deviasi, dan lain-lain.

Hasil Evaluasi Random Forest (Baseline):

- **Akurasi**: ~95.7%
- **ROC-AUC**: 0.9912

Model Random Forest menunjukkan performa yang sangat baik pada data yang telah diekstraksi fiturnya.

6. Pengembangan Model Final: Deep Learning (LSTM)

Untuk model final, digunakan arsitektur Long Short-Term Memory (LSTM). LSTM dipilih karena kemampuannya yang unggul dalam menangani data deret waktu (time-series), seperti data sensor IMU. Model ini dapat secara otomatis mempelajari pola temporal dalam data mentah tanpa memerlukan feature engineering manual.

Hasil Evaluasi LSTM pada Dataset SisFall (Full Dataset):

Metrik	ADL	FALL	Akurasi Keseluruhan	Macro Avg	Weighted Avg
Precision	0.89	0.84		0.87	0.87
Recall	0.93	0.77		0.85	0.87
F1-Score	0.91	0.81		0.86	0.87
Support	101.686	52.019	153.705		

- **Akurasi Keseluruhan:** 87%

7. Perbandingan Model

Berikut adalah perbandingan antara model baseline (Random Forest) dan model final (LSTM):

Fitur Perbandingan	Random Forest (Baseline)	LSTM (Final Model)
Pendekatan	Berbasis Fitur Statistik	Berbasis Sekuensial (Time-series)
Input Data	75 Fitur Statistik Manual	200 Timestep Data Mentah
Akurasi	~95.7% (Test Split)	87% (Full Dataset)
Kelebihan	Cepat, Interpretasi Mudah	Menangkap Pola Temporal, Tanpa Feature Engineering
Status	Baseline	Final (Produksi)

Catatan: Meskipun akurasi Random Forest terlihat lebih tinggi, evaluasi LSTM dilakukan pada seluruh dataset (153.705 window), yang memberikan gambaran performa yang lebih menyeluruh terhadap variasi data mentah di lapangan. LSTM lebih disukai untuk produksi karena kemampuannya mempelajari pola temporal secara langsung dari data mentah, mengurangi ketergantungan pada feature engineering manual yang bisa jadi tidak optimal untuk semua skenario jatuh.

8. Kesimpulan Akhir dan Rekomendasi

Berdasarkan seluruh proses eksperimen yang telah dilakukan:

1. **Performa Model:** Model LSTM menunjukkan kemampuan yang solid dalam mendeteksi jatuh dengan akurasi keseluruhan 87%. Model ini sangat efektif dalam mengenali aktivitas ADL (Recall 0.93), yang krusial untuk meminimalkan gangguan pada pengguna.
2. **Kelebihan LSTM:** LSTM belajar langsung dari urutan data mentah (200 timestep), menjadikannya lebih adaptif terhadap dinamika gerakan jatuh yang sebenarnya dibandingkan fitur statistik statis.
3. **Kesiapan Produksi:** Model telah dikemas ke dalam `src/inference_pipeline_dl.py` and siap untuk diintegrasikan ke dalam sistem Guardian Alert.

Paket Serah Terima (Handover) untuk Tim AI Engineering Untuk mengimplementasikan sistem ini di lingkungan produksi, berikut adalah komponen yang harus digunakan:

1. **Model File:** `models/fall_detection_lstm.h5` (Trained LSTM model).
2. **Inference Script:** `src/inference_pipeline_dl.py` (Gunakan class `FallDetectionInference`).
3. **Spesifikasi Input:**
 - Window size: 200 baris data sensor mentah (ADC values).
 - Kolom: 6 kolom pertama (Accel X/Y/Z dari ADXL345 + Gyro X/Y/Z dari ITG3200).
 - Frekuensi: 200 Hz.
4. **Format Output:**
 - `label` : "FALL (BAHAYA)" atau "ADL (AMAN)".
 - `confidence` : Nilai probabilitas (0-1).
 - `raw_probability` : Nilai probabilitas mentah (0-1).
5. **Rekomendasi Operasional:**
 - Gunakan threshold 0.8 untuk memicu alarm guna meminimalisir false alarm.
 - Pastikan konversi unit dilakukan sesuai formula:

- Accel: $\text{raw} * (32 / 8192) \text{ g}$
- Gyro: $\text{raw} * (1 / 14.375) \text{ deg/s}$

9. Jangkaan Hasil (Expected Outcomes)

Dengan implementasi sistem Guardian Alert ini, diharapkan dapat memberikan manfaat sebagai berikut:

- **Peningkatan Keamanan Lansia:** Deteksi jatuh yang cepat dan akurat akan memungkinkan respons darurat yang lebih cepat, mengurangi risiko cedera serius dan komplikasi jangka panjang.
- **Ketenangan Pikiran:** Keluarga dan pengasuh akan memiliki ketenangan pikiran yang lebih besar karena mengetahui bahwa ada sistem yang memantau keamanan lansia secara proaktif.
- **Data untuk Perbaikan Berkelanjutan:** Data dari penggunaan sistem di lapangan dapat digunakan untuk terus melatih dan meningkatkan model, menjadikannya lebih adaptif terhadap berbagai skenario jatuh dan aktivitas ADL.